

Neuralne mreze (13S053NM)

Prvi projektni zadatak


Marko Dragutinovic 2019/0731

Zadatak 1

Resavanje problema klasifikacije primenom neuralne mreze

Koriscen dataset 3.

Podela po klasama



Podatke smo podelili na trening i test skup kako bi mogli da testiramo neuralnu mrežu podacima koji nisu korišćeni za treniranje.

Ovim sprečavamo preobučavanje za dati skup podataka.

Kreiramo tri neuralne mreže.

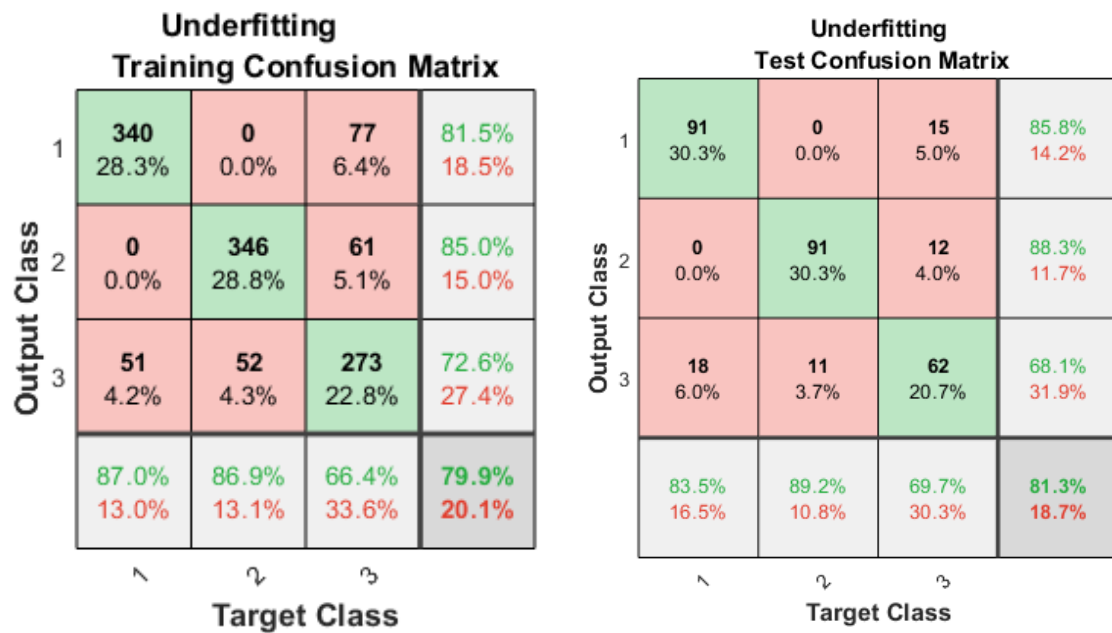
Jedna koja ne može da isprati dinamiku podataka. Ovo smo postigli malim brojem neurona u skrivenom sloju.

Druga koja preobučava. Postignuto velikim brojem neurona u skrivenim slojevima i većim brojem slojeva.

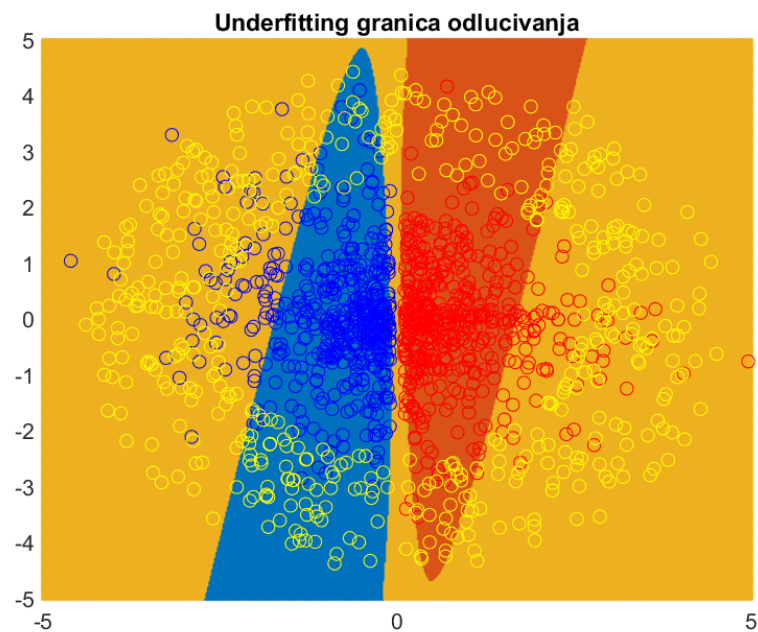
Treća koja na optimalan način klasifikuje podatke.

Sve mreže imaju iste parametre treniranja.

Treniranjem underfitting mreže dobijamo konfuzione matrice:



Nije doslo do preobucavanja, ali nam je preciznost niska.



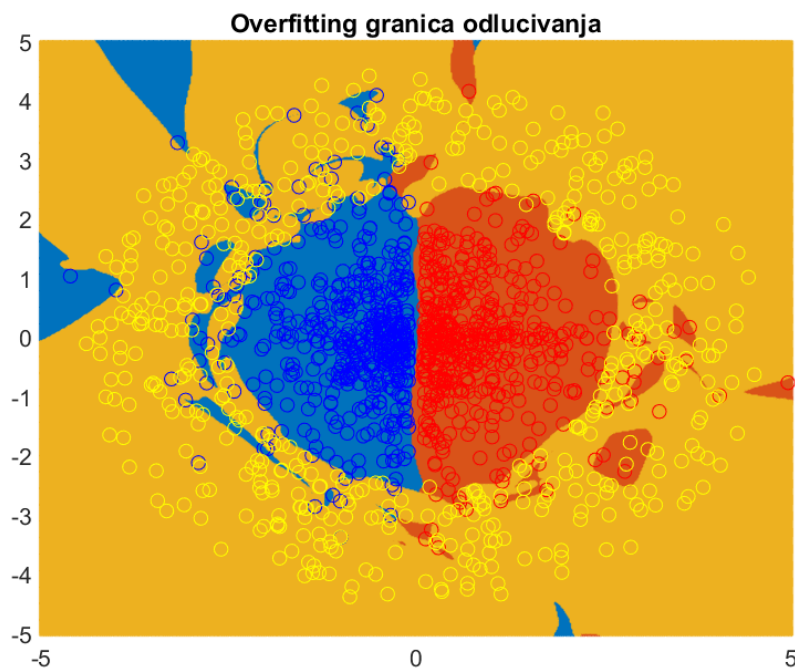
Na granici odlucivanja vidimo da su delovi u koje pripada jedna klasa neprecizni, te je doslo do underfittovanja.

Posmatramo neuralnu mrežu u kojoj je doslo do preobucavanja.

Overfitting Training Confusion Matrix					
Output Class	1	391 32.6%	0 0.0%	0 0.0%	100% 0.0%
	2	0 0.0%	398 33.2%	0 0.0%	100% 0.0%
	3	0 0.0%	0 0.0%	411 34.2%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%
Target Class					

Overfitting Test Confusion Matrix					
Output Class	1	98 32.7%	0 0.0%	10 3.3%	90.7% 9.3%
	2	0 0.0%	98 32.7%	7 2.3%	93.3% 6.7%
	3	11 3.7%	4 1.3%	72 24.0%	82.8% 17.2%
		89.9% 10.1%	96.1% 3.9%	80.9% 19.1%	89.3% 10.7%
Target Class					

Vidimo da je doslo do preobucavanja jer je nad trening skupom dobijena 100% tacnost. Dok je na test skupom dobijena 89% tacnost.



Na granici odlucivanja vidimo jasno definisane figure koje su odvojene od glavne figure.

Ovakva mreza je vrlo precizna za skup nad kojim je trenirana, ali zato sto je previse specificna nije dobra za generalnu upotrebu.

Optimalna mreza

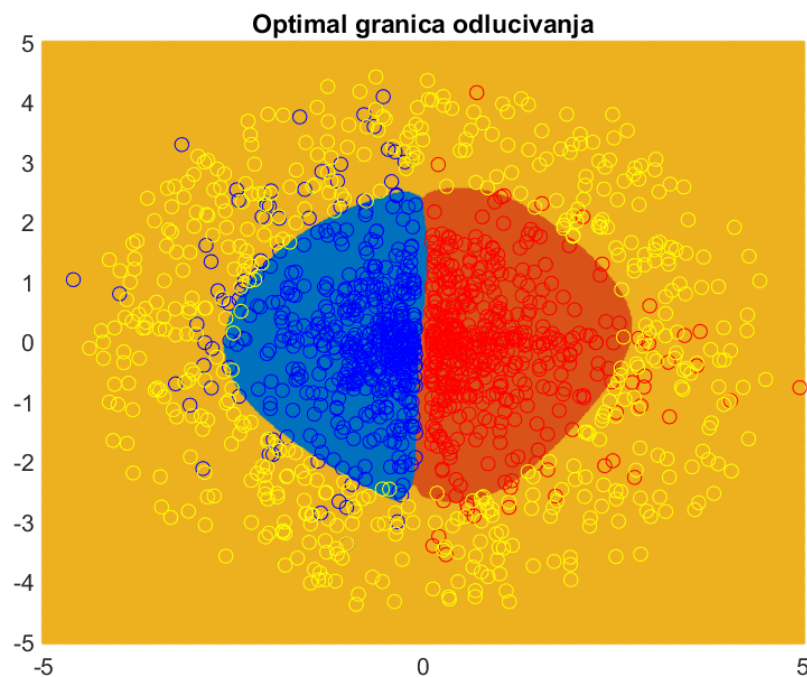
**Optimal
Training Confusion Matrix**

1	352 29.3%	0 0.0%	7 0.6%	98.1% 1.9%
2	0 0.0%	371 30.9%	6 0.5%	98.4% 1.6%
3	39 3.2%	27 2.2%	398 33.2%	85.8% 14.2%
	90.0% 10.0%	93.2% 6.8%	96.8% 3.2%	93.4% 6.6%
	↖	↗	↘	
	Target Class			

**Optimal
Test Confusion**

1	98 32.7%	0 0.0%	2 0.7%	98.0% 2.0%
2	0 0.0%	96 32.0%	2 0.7%	98.0% 2.0%
3	11 3.7%	6 2.0%	85 28.3%	83.3% 16.7%
	89.9% 10.1%	94.1% 5.9%	95.5% 4.5%	93.0% 7.0%
	↖	↗	↘	
	Target Class			

Kod optimalne mreze test i trening matrice konfuzije se razlikuju za manje od 1%.




Na grafiku granice odlucivanja vidimo da su klase vrlo jasno i celovito odredjene.

Pa imamo optimalnu neuralnu mrežu.

Zadatak 2

Traženje optimalnih hiperparametara metodom unakrsne validacije

Treba da konstruisemo feedforward neuralnu mrežu koriscenjem unakrsne validacije hiperparametara koristeći Resilient backpropagation trening funkciju nad Genres datasetom.



Na raspodeli vidimo da imamo mali broj Pop pesama, sto znaci da ce morati pazljivo da izaberemo trening, test i validacione skupove.

Iz svake klase cemo proporcionalno uzeti 75% za trening, 15% za validacioni i 15% za test skup.

Da nismo ovako izabrali neki od skupovi bi bio suvise mali tj. suvise veick za najmanju klasu, pa za nju ne bi mogli da dobijemo korisna predvidjanja.

Od hiperparametara odabrani su arhitektura, koja moze da ima neki od sledeceg neurona u hidden layeru: {[5],[8],[5,5],[8,8],[10,10],[8,6,4],[5,5,5],[10,10,10],[3,3,3]}

Povecava broj pojacanja, znacajno utice na performanse, generalno se eksperimentalno dobija.

Konstanta ucenja : [0.5,0.25,0.1,0.01,0.001]

Ubrzava ili usporava brzinu kojom se obucava mreza.

Tezina klase za klasu 2 : [1,2,4,8]


Daje odredjenim klasama vecu tezina kako bi nadoknadili manji broj podataka te klase.

Dobijene vrednosti hiperparametara:

Arhitektura mreze : [8]

Konstanta ucenja : 0.5

Tezina klase : 1



		Training Confusion Matrix						Test Confusion Matrix			
Output Class	Rap	1146 32.5%	41 1.2%	270 7.7%	78.7% 21.3%	Output Class	Rap	290 32.9%	7 0.8%	71 8.1%	78.8% 21.2%
	Pop	4 0.1%	42 1.2%	37 1.0%	50.6% 49.4%		Pop	0 0.0%	16 1.8%	11 1.2%	59.3% 40.7%
	RnB	328 9.3%	286 8.1%	1372 38.9%	69.1% 30.9%		RnB	79 9.0%	69 7.8%	338 38.4%	69.5% 30.5%
		77.5% 22.5%	11.4% 88.6%	81.7% 18.3%	72.6% 27.4%			78.6% 21.4%	17.4% 82.6%	80.5% 19.5%	73.1% 26.9%
		Target Class						Target Class			
		Rap	Pop	RnB				Rap	Pop	RnB	

Preciznost: $794/881 = 90.1\%$

Senzitivnost: $16/92 = 17.4\%$

Specifcnost: $778/789 = 98.6\%$

Na osnovu matrice konfuzije test i trening skupova, vidimo da nije doslo do preobucavanja. Mreza prepoznaje Rap i Rnb sa solidnom tacnoscu.

Medjutim Pop koji je imao mnogo manji data set od ostalih, mreza ne moze da predvidi sa boljom tacnoscu od bacanja novcica.

Takodje,metodom unakrsne validacije optimalna tezina klase za Pop je 1. Sto znaci da mreza ne moze da se koristi za prepoznavanje Pop pesama, dok se ne poveca dataset pesama.